EDUCACIÓN VIAL Y CONSULTA NORMATIVA · COIP & LOTTTSV (ECUADOR)

Vía Segura

Simulador educativo de situaciones viales y agente consultor con recuperación vectorial (RAG), verificación de citas y cálculo determinista de sanciones (SBU 2026: $482.00 USD).

URL PÚBLICA CLOUD RUN	CORPUS NORMATIVO RAG	PRECISIÓN RAG (HIT@1 / HIT@5)	PRUEBAS PYTEST + HUMO
g8-vial...run.app	641 artículos	87.5% / 100%	72 + 6/6
us-central1 · HTTPS activo	Vigentes en ChromaDB (e5-small)	Evaluado en 2 bancos de 20 casos	Pipeline verde · p95 = 49.2 s

INTEGRANTE 1 · MIN 00:00 A 05:00 (5 MIN)

Luis Naranjo

1. Problema y usuario (1 min) + 2. Demo en vivo sobre la URL pública en Cloud Run (4 min): caso con cita, regla de silencio y confirmación humana.

INTEGRANTE 2 · MIN 05:00-07:00 Y 09:00-10:00 (3 MIN)

Fausto Cando

3. Arquitectura y almacenamiento en producción (2 min) + 5. Seguridad de credenciales, timeout, reintentos y conmutación a respaldo en 17 ms (1 min).

INTEGRANTE 3 · MIN 07:00-09:00 Y 10:00-12:00 (4 MIN)

Isidoro Guaman

4. Evidencias: evaluación RAG vs Semana 3, pipeline en verde y pruebas funcionales en la URL (2 min) + 6. Limitaciones conocidas y uso de IA (2 min).

1. ¿Qué problema resuelve Vía Segura y para quién?

Orientación legal verificada en tránsito ecuatoriano sin artículos inventados ni multas mal calculadas.

EL PROBLEMA REAL

Riesgo de alucinación legal

>> Desconocimiento normativo:
Conductores y peatones no saben qué artículo del COIP o LOTTTSV aplica en situaciones reales.

>> Alucinación en LLMs libres:
Un chatbot genérico inventa numerales, cita normas derogadas o confunde clases de contravenciones.

>> Errores aritméticos en multas:
Los modelos usan SBU antiguos ($450/$460) e ignoran la reforma RO 512 (2021) sobre puntos de licencia.

USUARIOS OBJETIVO

5 Perfiles viales ciudadanos

>> Conductor Particular (Lic. B):
Cruces en semáforo, uso del celular, estacionamiento y límites urbanos.

>> Conductor Profesional (Lic. C/D/E):
Transporte de pasajeros/carga, llantas lisas y exceso de pasajeros.

>> Motociclista (Lic. A):
Uso de casco homologado, chaleco retroreflectivo y rebase seguro.

>> Ciclista y Peatón:
Preferencia en paso cebra, respeto a ciclovías, aceras y ambulancias.

NUESTRA SOLUCIÓN

El LLM propone; Python valida

>> Citas verificadas con RAG:
Solo responde usando los 641 artículos vigentes en ChromaDB (umbral coseno <= 0.45).

>> Cálculo 100% en Python:
Multas exactas con SBU 2026 ($482.00 USD) desde tabla canónica auditada, nunca calculadas por el LLM.

>> Interfaz ciudadana clara:
Una sola línea de sanción para actuar y panel plegable de Detalles técnicos para el tribunal.

Principio de diseño: El modelo redacta en lenguaje ciudadano; Python verifica la cita y calcula la multa.

TRAMO 2 · MIN 01:00 A 05:00 (4 MIN)

DEMO EN VIVO · URL PÚBLICA CLOUD RUN

Expone: Luis Naranjo

2. Demostración en vivo sobre https://g8-vial-834435723683.us-central1.run.app/

Verificación de /health (200 OK · 641 fragmentos) y ejecución de los 3 escenarios exigidos por el tribunal.

PASO 1 · MIN 01:30 - 02:45

Caso normal con cita y SBU

>> Botón 'Pasarse luz roja':
Consulta: 'Me pasé un semáforo en rojo, ¿cuántos puntos pierdo y cuánto es la multa?'

>> Fuente legal verificada:
Recupera y cita explícitamente COIP Art. 389 (Contravención de 4.ª clase).

>> Cálculo exacto en 1 línea:
'Si cometes esta infracción: multa de $144.60 (30% del SBU) y -6 puntos.' (30% de $482 = $144.60).

>> Detalles técnicos plegables:
Muestra distancia coseno, Top-5 de ChromaDB y bitácora de vueltas del agente.

PASO 2 · MIN 02:45 - 03:45

Pregunta fuera de tema

>> Botón 'Consulta ajena a tránsito':
Consulta: '¿Cómo se prepara un encebollado y cuánto cuesta la matrícula?'

>> Abstención activa (Silencio):
El filtro de anclas viales y derivación ANT detecta que está fuera del alcance normativo.

>> Cero artículos inventados:
Informa con claridad que solo atiende normativa vial y deriva trámites a la ANT.

>> UI sin falsos aprobados:
Oculta automáticamente la tarjeta de confirmación humana cuando aplica regla de silencio.

PASO 3 · MIN 03:45 - 05:00

Confirmación humana y alcance

>> Acción con aprobación humana:
Tarjeta 'Confirmar acción: el asistente necesita tu aprobación para continuar' -> Confirmar / Descartar.

>> Herramienta prohibida:
En 'Pedir borrar una multa', bloquea anular_multa_ant con HerramientaNoPermitidaError.

>> Documento envenenado:
En 'Cruzar semáforo en rojo', neutraliza el fragmento malicioso y mantiene la multa oficial ($144.60).

>> Simulador Vial:
Escenarios de máximo 2 frases con evaluación legal inmediata.

Contingencia lista: «La plataforma está despertando; mientras tanto, esta es la grabación de hoy» (video 2 min).

3. Arquitectura del Sistema y Almacenamiento (ADR-0003)

Contenedor Docker en Google Cloud Run (g8-vial, 2 GiB RAM) con Agente Pydantic y ChromaDB embebido.

1. Frontend React + TS
SPA estática · Sesión UUID

->

2. FastAPI (Cloud Run)
/chat · /escenarios · /health

->

3. Agente Tool Calling
Groq/Gemini · Tope 6 vueltas

->

4. ChromaDB + Python
641 vectores · SBU $482.00

AGENTE CONTROLADO

6 Herramientas Permitidas (Pydantic extra='forbid')

`buscar_normativa_rag`	Búsqueda vectorial Top-5 en ChromaDB (solo vigentes).
`identificar_contravencion`	Cruza artículo COIP contra el catálogo oficial JSON.
`calcular_sancion`	Multiplica % SBU x $482.00 USD y puntos en Python.
`verificar_cita_y_seguridad`	Valida cita en fragmentos y neutraliza inyecciones.
`registrar_progreso`	Actualiza métricas de sesión tras confirmación.
`ajustar_dificultad`	Recomienda nivel según desempeño (>=80% / <50%).

Fuera de alcance bloqueadas: anular_multa_ant, modificar_puntos_licencia, emitir_fallo_judicial

PERSISTENCIA Y DECISIONES

Dónde viven los datos en producción (ADR-0003)

Índice RAG (641 vectores)	Dentro de la imagen Docker (solo lectura).
Documentos COIP / LOTTTSV	Dentro de la imagen Docker (solo lectura).
Configuración y SBU ($482)	Archivos JSON en imagen (solo lectura).
Escenarios y progreso activo	Memoria RAM (se pierden al reiniciar; aceptado).
Historial / Datos personales	No se almacenan (privacidad por diseño).
Métricas operativas LLM	Cloud Logging (latencia y estado, sin PII).

¿Por qué en la imagen? Descartamos BD vectorial paga; logra arranque de 12 s y costo $0 en reposo.

Alternativa descartada: Pinecone/Cloud SQL externo -> Incluir 641 vectores en la imagen evita red extra y costos fijos.

4. Evaluación Cuantitativa del RAG y Agente (docs/07-evaluacion.md)

Evaluado con python eval/run_eval.py sobre 2 bancos de 20 casos (referencia e independiente sin números de artículos).

RESULTADOS VERIFICABLES

Métricas alcanzadas en ambos bancos (40 casos)

MÉTRICA	META	REF (20)	INDEP (20)
Hit@1 (Artículo Top-1)	>= 80%	87.5% (14/16)	87.5% (14/16)
Hit@5 (Artículo Top-5)	>= 90%	100.0% (16/16)	100.0% (16/16)
Regla de Silencio	>= 90%	100.0% (4/4)	100.0% (4/4)
Escenarios válidos COIP	>= 90%	100.0%	100.0%
Cálculo SBU ($482.00)	100%	100.0%	100.0%
Tool Calling Pydantic	100%	100.0%	100.0%

Ambos bancos superan todos los umbrales de la rúbrica sin depender de palabras clave quemadas.

DIAGNÓSTICO Y MEJORA

Evolución técnica frente a la Semana 3

>> Limpieza de 153 fragmentos huérfanos:
De 794 artículos brutos, filtramos encabezados vacíos y textos derogados para indexar 641 artículos vigentes.

>> Embeddings multilingual-e5-small:
Uso de prefijos 'query:' y 'passage:' con chunking de 900 caracteres y overlap de 150.

>> Tesauro sin números de artículos:
Eliminamos referencias directas a 'Art. 389' en el tesauro para probar recuperación semántica genuina.

>> Anclas de dominio vial:
Filtro semántico que evita que preguntas culinarias, laborales o médicas crucen el umbral de 0.45.

5. Pruebas Funcionales contra Cloud Run y CI/CD

Validación automatizada en GitHub Actions (.github/workflows/ci-cd.yml) y smoke tests contra la URL pública.

6/6 CASOS EN CLOUD RUN

Pruebas funcionales contra la URL (tests/smoke.py)

1. [salud] GET /health	200 OK · 641 fragmentos	PASA
2. [caso 1] POST /chat (semáforo)	200 OK · Cita Art. 389	PASA
3. [caso 2] POST /chat (celular)	200 OK · Cita Art. 391	PASA
4. [fuera] POST /chat (fuera tema)	200 OK · Se abstiene	PASA
5. [inyeccion] POST /chat (ataque)	200 OK · Bloquea ataque	PASA
6. [invalida] POST /chat (vacía)	422 Unprocessable	PASA

RESULTADO REGISTRADO: 6/6 pasan · p95 = 49.2 s

Arranque en frío medido en Cloud Run: 12 s

AUTOMATIZACIÓN ANTES DE DESPLEGAR

Pipeline CI/CD en Verde (GitHub Actions)

>> 1. Escaneo de secretos (Gitleaks):
Verifica en cada push que no existan claves API en el código ni en el historial Git.

>> 2. 72 Pruebas con Pytest (pytest -q):
Ejecuta pruebas unitarias y de integración usando el servidor simulado local sin gastar cuota.

>> 3. Evaluación del RAG (eval/run_eval.py):
Comprueba que Hit@1, Hit@5 y Regla de Silencio superen la rúbrica antes de construir la imagen.

>> 4. Despliegue a Cloud Run + Smoke Test:
Publica en el servicio g8-vial (us-central1) y ejecuta automáticamente tests/smoke.py contra la URL.

6. Protección de Credenciales y Resiliencia ante Fallas

Dónde viven las claves y qué ocurre exactamente cuando el proveedor de IA falla o recibe inyecciones.

1. CERO CLAVES EXPUESTAS

Dónde viven las claves

>> Variables protegidas en GCP:
GROQ_API_KEY y GEMINI_API_KEY viven solo en la configuración segura de Cloud Run.

>> GitHub Secrets en CI/CD:
GCP_PROJECT_ID y GCP_SA_KEY están cifrados en el repositorio y nunca se imprimen en logs.

>> Plantilla .env.example limpia:
El archivo .env local está en .gitignore; ni el Dockerfile ni el historial contienen secretos.

2. ESTABILIDAD LLM (APP/SERVICES/LLM.PY)

Qué pasa si el modelo falla

>> Tiempo límite (Timeout):
Cada llamada aplica timeout configurable (12-30 s) para no colgar peticiones.

>> Reintentos con espera creciente:
Backoff exponencial ante errores transitorios 429 (rate limit) o 5xx.

>> Conmutación en 17 ms:
Al configurar un modelo inexistente (error 404), el proveedor de respaldo contestó en 17 ms sin error 500.

>> Mensaje claro al usuario:
Si todo falla, devuelve HTTP 503 con Retry-After y cuenta regresiva.

3. DEFENSA EN CAPAS

Anti-Inyección y Privacidad

>> Inyección en usuario y RAG:
verificar_cita_y_seguridad detecta 'ignora las reglas' tanto en la pregunta como en documentos envenenados.

>> Límites de entrada y tasa:
Tope de 500 caracteres en /chat, max_tokens de salida y limitador de peticiones en /escenarios.

>> Logs sin PII ni secretos:
Solo se registra latencia, proveedor y código de estado; nunca preguntas ni claves.

7. Limitaciones Conocidas, Uso de IA y Cierre

Transparencia técnica sobre el alcance actual (README.md / ADR-0003) y auditoría del trabajo con IA.

TRANSPARENCIA TÉCNICA

5 Limitaciones Conocidas en Producción

>> 1. Estado efímero en memoria:
Escenarios y progreso viven en RAM y se pierden al reiniciar Cloud Run. Se acepta por ser práctica educativa anónima.

>> 2. Respaldo simulado local:
El fallback en producción es el proveedor simulado determinista, priorizando disponibilidad 100% sobre variedad.

>> 3. Rate limiting en memoria:
/escenarios limita por sesión en RAM y /chat corta a 500 caracteres; escalar a varias instancias requeriría Redis.

>> 4. Arranque en frío (12 s):
Con min-instances=0, despertar el contenedor y cargar el modelo E5 tarda ~12 s.

>> 5. Alcance educativo:
No sustituye el portal oficial de la ANT ni constituye asesoría jurídica.

DEFENSA ANTE EL TRIBUNAL (MIN 12-15)

Auditoría de Uso de IA Generativa

>> ¿Qué se generó con apoyo de IA?:
Borradores de esquemas Pydantic, plantillas de pruebas unitarias, estructura del frontend React y documentación base.

>> ¿Qué revisó y corrigió el equipo?:
1) Filtrado de 153 fragmentos huérfanos del corpus; 2) Separación entre puntos COIP y reforma RO 512 (2021); 3) Simplificación visual para el ciudadano.

>> ¿Qué pruebas lo respaldan?:
72 pruebas unitarias/integración en pytest, 40 casos RAG en 2 bancos (87.5% Hit@1, 100% Hit@5) y 6/6 smoke tests en Cloud Run.

>> Listos para preguntas (Min 12-15):
Fausto Cando · Isidoro Guaman · Luis Naranjo - Grupo 8.