

SEMINARIO DE INGENIERÍA DE SOFTWARE CON IA GENERATIVA · CASO N.° 08 · GRUPO 8

Vía Segura

Educación vial y consulta normativa · COIP y LOTTTSV (Ecuador)

Simulador educativo y agente consultor con RAG, verificación de citas y cálculo determinista de sanciones (SBU 2026: $482.00 USD).

Luis Francisco Naranjo Espinosa · Fausto Eduardo Cando Cando · Isidoro Guaman Cazho

AMBATO 2026

Problema y usuario

1 El problema real

- No se sabe qué artículo del COIP o la LOTTTSV aplica a cada situación.
- Los LLM libres inventan numerales y citan normas derogadas.
- Usan SBU antiguos ($450 o $460) e ignoran la reforma RO 512 (2021).

2 Usuarios objetivo

- **Conductor (B):** semáforos, celular, estacionamiento.
- **Profesional (C/D/E):** pasajeros, carga, llantas lisas.
- **Motociclista (A):** casco, chaleco, rebase seguro.
- **Ciclista y peatón:** paso cebra, ciclovías, aceras.

3 Nuestra solución

- Citas verificadas con RAG: 641 artículos vigentes, umbral coseno ≤ 0.45.
- Multas 100 % en Python con el SBU 2026 de $482.00.
- Una línea de sanción y panel plegable con detalles técnicos.

Principio de diseño: el modelo redacta en lenguaje ciudadano; Python verifica la cita y calcula la multa.

Demo en vivo sobre la URL pública

Primero: GET /health → 200 OK · 641 fragmentos

A Caso normal con cita y SBU

«Me pasé un semáforo en rojo, ¿cuántos puntos pierdo y cuánto es la multa?»

- Cita COIP Art. 389 (4.ª clase)
- Multa de $144.60 (30 % del SBU)
- −6 puntos de licencia
- Detalles: distancia coseno, Top-5, bitácora

B Pregunta fuera de tema

«¿Cómo se prepara un encebollado y cuánto cuesta la matrícula?»

- Se abstiene: solo atiende normativa vial
- Deriva los trámites a la ANT
- Cero artículos inventados

C Confirmación humana y alcance

«Pedir borrar una multa» y «Cruzar semáforo en rojo»

- Tarjeta Confirmar o Descartar
- Bloquea anular_multa_ant
- Neutraliza el documento envenenado y mantiene $144.60

Arquitectura y datos en producción

1 · Frontend
React + TypeScript, SPA estática, sesión UUID

2 · API
FastAPI en Cloud Run: /chat /escenarios /health

3 · Agente
Tool calling Groq/Gemini, tope de 6 vueltas

4 · Datos
ChromaDB, 641 vectores, SBU $482.00

Agente controlado: 6 herramientas permitidas

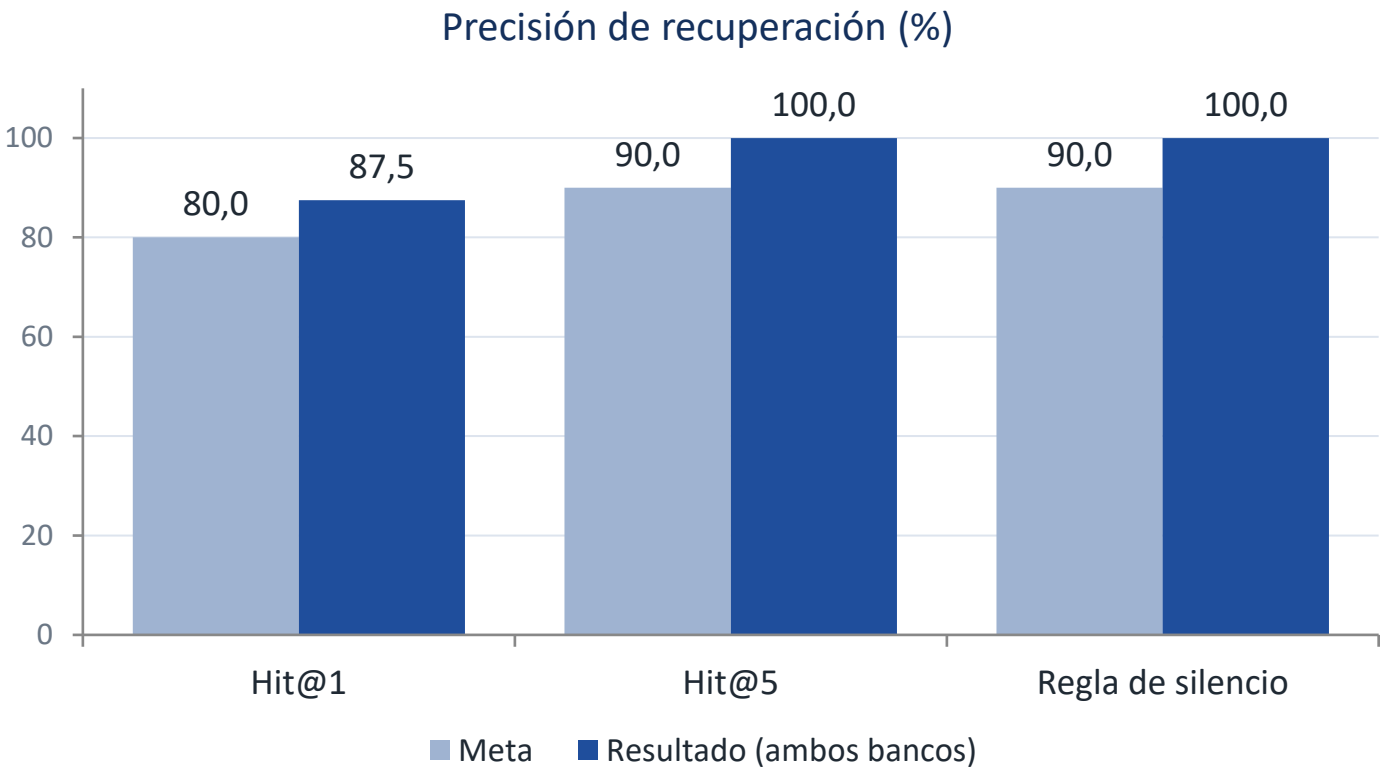
- **buscar_normativa_rag:** Top-5 vectorial, solo vigentes
- **identificar_contravencion:** cruza el artículo con el catálogo
- **calcular_sancion:** % SBU × $482.00 y puntos
- **verificar_cita_y_seguridad:** valida la cita y frena inyecciones
- **registrar_progreso:** guarda el avance
- **ajustar_dificultad:** sube con ≥ 80 %, baja con < 50 %

Bloqueadas: anular_multa_ant, modificar_puntos_licencia, emitir_fallo_judicial

Dónde viven los datos

- **Imagen Docker (solo lectura):** índice RAG, COIP/LOTTTSV y SBU
- **Memoria RAM:** escenarios y progreso; se pierden al reiniciar
- **No se guarda** historial ni datos personales
- **Sin Pinecone ni Cloud SQL:** arranque de 12 s y $0 en reposo

Evidencias: evaluación del RAG



multilingual-e5-small · fragmentos de 900 caracteres con solapamiento de 150 · umbral coseno 0.45 · bancos sin números de artículos

641 artículos vigentes (de 794 brutos)

153 fragmentos huérfanos eliminados

2 × 20 casos: referencia e independiente

100 % cálculo SBU, tool calling y escenarios COIP

Pruebas en la URL y pipeline en verde

81
pruebas pytest

15/15
smoke tests pasan en Cloud Run

28.0 s
latencia p95

12 s
arranque en frío medido: health

Caso (tests/smoke.py)	Resultado · estado
Salud: GET /health	200 OK · 641 fragmentos ✓
Caso 1: POST /chat (semáforo)	200 OK · cita Art. 389 ✓
Caso 2: POST /chat (celular)	200 OK · cita Art. 391 ✓
Fuera de tema: POST /chat	200 OK · se abstiene ✓
Inyección: POST /chat	200 OK · bloquea el ataque ✓
Inválida: POST /chat (vacía)	422 Unprocessable ✓

Casos principales; la suite completa suma 15 casos, todos en verde.

Corrida en verde: github.com/edudigital2019/simulador-situaciones-viales/actions/runs/43149871887

Pipeline CI/CD en GitHub Actions

1. Gitleaks: sin claves en el código ni en el historial
2. 81 pruebas pytest con servidor simulado local
3. Evaluación RAG: Hit@1, Hit@5 y silencio superan la rúbrica
4. Despliegue a Cloud Run y smoke test contra la URL

Seguridad y fallas del modelo

1 Cero claves expuestas

- GROQ_API_KEY y GEMINI_API_KEY solo en la configuración segura de Cloud Run.
- GitHub Secrets cifrados: GCP_PROJECT_ID y GCP_SA_KEY.
- Sin secretos en .env.example, Dockerfile ni historial (Gitleaks).

2 Estabilidad del LLM

- Timeout configurable de 12 a 30 s.
- Reintentos con espera creciente ante 429 y 5xx.
- Respaldo en 17 ms ante un modelo inexistente (404), sin error 500.
- HTTP 503 con Retry-After y cuenta regresiva.

3 Defensa en capas

- verificar_cita_y_seguridad revisa la pregunta y los documentos recuperados.
- Límites: 500 caracteres en /chat, max_tokens y limitador en /escenarios.
- Logs sin datos personales: solo latencia, proveedor y estado.

Limitaciones, uso de IA y cierre

! 5 limitaciones conocidas

- Estado efímero en memoria; aceptado por ser práctica anónima.
- Respaldo simulado local: prioriza disponibilidad.
- Rate limiting en memoria; varias instancias requerirían Redis.
- Arranque en frío de 12 s (min-instances=0).
- Alcance educativo: no sustituye a la ANT ni es asesoría jurídica.

IA Auditoría de uso de IA

- **La IA generó:** esquemas Pydantic, plantillas de pruebas, estructura del frontend y documentación base.
- **El equipo corrigió:** filtró 153 fragmentos huérfanos y separó los puntos COIP de la reforma RO 512.
- **Respaldo: 81** pytest, 40 casos RAG (87.5 % Hit@1, 100 % Hit@5) y 15/15 smoke tests.

Gracias!

El modelo redacta; el código verifica y calcula.

Grupo 8
Fausto Cando · Isidoro Guaman · Luis Naranjo